

Phishing

"Phishing" es cuando se engaña a la gente para que entregue información secreta (como sus contraseñas o los datos de su tarjeta de crédito) en un sitio web falso que se disfraza para parecer un sitio web de confianza.

A la gente se le envían enlaces a estos sitios web de phishing falso en correos electrónicos o mensajes instantáneos. ¿Cómo pueden saber si es seguro hacer clic en un enlace?

En este proyecto, conocerás la investigación que se está realizando para entrenar a los sistemas de aprendizaje automático a fin de que puedan predecir si un enlace es a un sitio web de phishing o a un sitio web legítimo.



Esta hoja de trabajo de proyecto está bajo una licencia de Creative Commons Reconocimiento-Licencia de Compartir-Alike http://creativecommons.org/licenses/by-nc-sa/4.0/

Empecemos por mirar algunas de las partes que componen una URL (dirección web):



número de puerto	A qué puerto conectar.
	Si no se especifica, el navegador web utilizará el 80 (si el protocolo es "http") o el 443 (si el protocolo es "https").
	El 80 y el 443 son los números de puerto "estándar" que se utilizan casi siempre, pero los sitios web pueden utilizar otros puertos si lo desean.
host	host con el que se conectará el servidor web.
	Esta puede ser una dirección numérica con puntos (denominada "dirección IP") como 104.20.74.246
	O puede ser un nombre de host basado en texto (denominado un "nombre de dominio") como machinelearningforkids.co.uk que el navegador web utilizará para buscar la dirección IP de (llamada "búsqueda DNS").
	Puedes utilizar https://whois.net para buscar la dirección IP de un nombre de dominio. Esto también te permitirá averiguar cuándo se ha registrado un nombre de dominio y cuánto tiempo va a transcurrir antes de que caduque el registro de nombres de dominio.
contraseña	La contraseña que debe utilizarse para identificar al usuario
	Si no se especifica, el navegador de Internet no utilizará una contraseña.
usuario	El nombre de usuario a utilizar para identificar al usuario
	Si no se especifica, el navegador web no utilizará un nombre de usuario.
protocolo	El protocolo de comunicación que debe utilizar el navegador de Internet. Este será "https" para conexiones seguras, o "http" para conexiones inseguras.

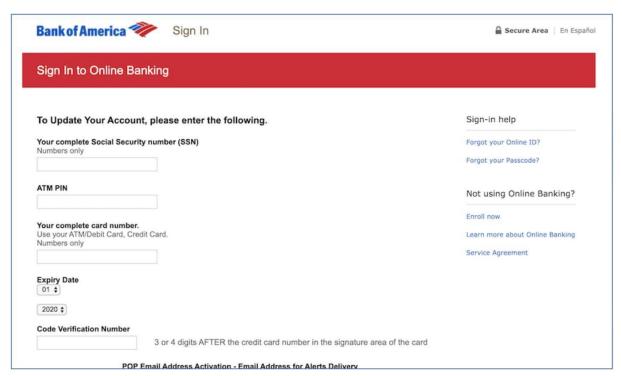
Otra cosa que entender es "redireccionar". A veces, una dirección web te enviará a otra dirección web. Por ejemplo, si visitsa https://bit.ly/39XEEfP terminas en https://machinelearningforkids.co. uk porque la primera dirección es una redirección. Redireccionar oculta el destino real de una URL. Puedes unirte a varios. Por ejemplo, si visitas https://bit.ly/35Jnlf8 terminas en https://www.bbc.co. uk/noticias después de 4 redirecciones.

https://bit.ly/35Jnlf8 → https://tinyurl.com/wrcfg53 → https://bbc.in/2FICKBL → http://news.bbc.co.uk → http://www.bbc.co.uk/news

Ahora mira este URL:

http://login.bankofamerica.com@www.josueizagirre.com/wpcontent/cache/login.bankofamerica.com.uplogad/up date.html

La página web se parece a esto:



Este sitio web no tiene nada que ver con el verdadero Banco de América.

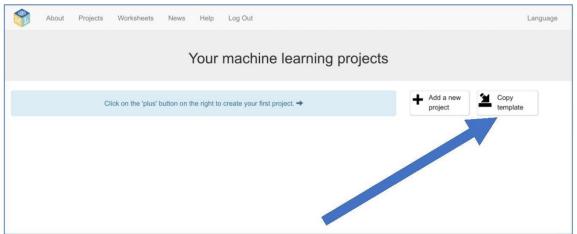
Esta es una URL de phising

¿Cómo lo sabes?

número de puerto	La página está utilizando el puerto 80-un sitio web de la banca real estaría usando el puerto estándar seguro 443.
host	El nombre de dominio para el sitio web es www.josueizagirre.com, que no es el verdadero dominio oficial para Bank of America.
nombre de usuario	La URL está dando el nombre de usuario "login.bankofamerica.com" aunque el servidor web ignora esto. Poner un usuario como este aquí es un truco para hacer que parezca que la dirección web es "login.bankofamerica.com"
protocolo	La página está usando "http"- un sitio web de la banca real estaría usando el protocolo seguro "https".

¿Crees que una ordenador podría ser entrenado para predecir que esta URL era para un sitio web de phishing?

- 1. Ir a https://machinelearningforkids.co. uk/ en un navegador web
- 2. Haz clic en "Empezar"
- **3.** Haz clic en "**Iniciar sesión**" y escribe tu usuario y contraseña. Si no tienes un usuario, pídele a tu profesor o jefe de grupo que te cree uno. Si no recuerdas tu usuario o contraseña, pídele a tu profesor o líder de grupo que la reinicie.
- 4. Pulsa en "Proyectos" en la barra de menú superior
- 5. Haz clic en el botón "Copiar plantilla".



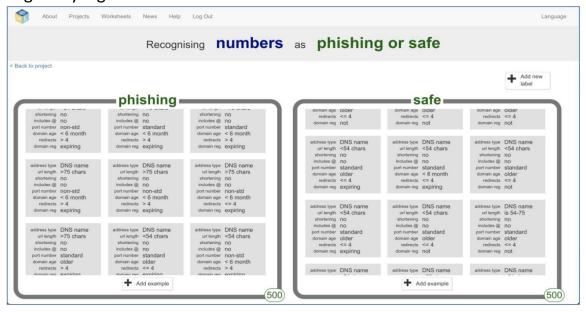
- **6.** Busca la plantilla Phishing y luego haz clic en "**Import**".
- **7**. Ahora deberías ver "**Pishing**" en tu lista de proyectos. Haz clic en él.



8. Esta plantilla incluye un conjunto de datos de aprendizaje de ejemplo para ayudarte a ahorrar tiempo. Haz clic en el botón "**Entrenar**" para revisar los datos de entrenamiento.



Los datos de entrenamiento de muestra incluyen detalles sobre 1000 URL. 500 fueron identificados como sitios web de phishing, y 500 fueron identificados como sitios web seguros y legítimos.



Cada URL se ha descrito utilizando los atributos siguientes:

atributo	descripción	posibles valores	motivo
tipo de dirección	¿Se ha proporcionado la dirección del host en la URL como una dirección IP numérica, o un nombre de dominio basado en texto?	Nombre del DNS si la URL tenía un nombre de dominio basado en texto (como "machinelearningforkids.co.uk") Dirección IP si el URL tenía un nombre de host numérico (como "104.20.75.246")	El uso de direcciones IP es inusual, y a veces una forma de ocultar el destino real de una dirección web
atributo	descripción	posibles valores	motivo

longitud de	¿Qué tan larga es la URL?	<54 caracteres	Las URL de phishing en los
URL		si la URL tiene menos de 54 caracteres.	correos electrónicos tienden a
ONL		entre 54-75	ser más largas, ya que es más
		si la URL tiene entre 54 y 75	fácil ocultar la parte sospechosa
		caracteres.	de la dirección si la URL es muy
		>75 caracteres	larga.
		si la URL tiene más de 75 caracteres.	
abreviación	¿Utiliza la URL un servicio de	sí	Los servicios de acortamiento,
abieviación	abreviación, como bit.ly o	si la URL utiliza un servicio de	como cualquier
	tinyurl.com?	acortamiento reconocido	redireccionamiento, hacen difícil
	Los servicios de acortamiento	no	saber el verdadero destino de
	usan redirecciones para hacer	si la URL no utiliza un servicio de	una URL, por lo que son útiles
	una versión corta de una	acortamiento reconocido	para disfrazar un enlace de
	dirección web larga.		phishing.
incluye @	¿Incluye la URL el símbolo @?	sí	Los enlaces legítimos con
		si la URL incluye una @	usuario/contraseñas son
		no	inusuales.
		si el URL no incluye @	Los enlaces de phishing
		, ,	aprovechan el hecho de que
			muchos usuarios no se dan
			cuenta de que nada antes de una
			@ es un usuario/contraseña y
			ponen una dirección web falsa
			en su lugar.
número de	¿Utiliza la URL los números de	estándar	El uso de números de puerto no
puerto	puerto estándar para las	si el URL utiliza el puerto estándar 80 o	estándar es inusual.
	páginas web?	443	
		no estándar	
		si el URL utiliza un número de puerto	
		personalizado y no estándar	
edad de	¿Cuánto tiempo hace que se	< 6 meses	Los sitios web de phishing a
dominio	registró el nombre de dominio?	si el nombre de dominio se registró	menudo no existen hace mucho
		hace menos de 6 meses	tiempo. Son reportados y
	Por ejemplo, machinelearningforkids.co.uk	más antiguo	descubiertos rápidamente, así que los atacantes crean nuevos
	se registró el 17 de abril de	si el dominio fue registrado hace más	sitios y registran nuevos
	2017, lo que puede	de 6 meses	dominios. Esto significa que un
	comprobarse en whois.net		enlace a un dominio que se
			registró hace mucho tiempo
			puede ser más probable que sea
			legítimo.
redireccionar	¿Cuántas redirecciones tiene	<= 4	Una o dos redirecciones es
	que seguir el navegador para	si hay cuatro o menos redirecciones	común para ayudar a los
	llegar a la página final?	desde el URL a la página web final	desarrolladores de sitios web a
		>4	administrar su sitio, pero más
		si hay más de cuatro redirecciones	que eso es posiblemente
		para llegar a la página web final	sospechoso como señal de que
			se está tratando de ocultar el
			verdadero destino de una URL.

atributo	descripción	posibles valores	motivo
----------	-------------	------------------	--------

registro de	¿Se ha registrado el dominio durante	expira	Los sitios web de phishing a
dominio	muchos años, o va a expirar pronto?	si el nombre de dominio va a expirar en el próximo año no si el nombre de dominio no	menudo no existen por mucho tiempo. Se denuncian y se descubren rápidamente, por lo que los atacantes sólo
		va a expirar en el próximo año	registran los nombres de dominio durante un corto período de tiempo para ahorrar costes.
			Es más probable que las grandes organizaciones de buena reputación registren nombres de dominio durante varios años.

Por ejemplo:

http://login.bankofamerica.com@www.josueizagirre.com/wpcontent/cache/login.bankofamerica.com.uplogad/up date.html

se mostrarán en los datos de entrenamiento como:

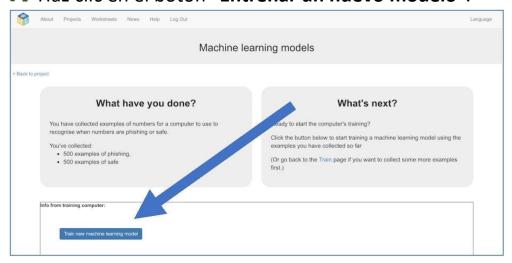
address type
url length >75 chars
shortening no
includes @ yes
port number standard
domain age older
redirects <= 4
domain reg expiring

Desplázate por el resto de los datos de entrenamiento que has importado.

Las URLs de phishing del proyecto de ejemplo fueron reportados por los usuarios de todo el mundo al sitio web https://phishtank.com ya que es una fuente confiable para obtener un gran número de enlaces de phishing. Los atributos elegidos para describir las URL son sólo un ejemplo para el primer proyecto de inicio. Después de haberlo intentado, observarás algunos otros atributos que se pueden utilizar para entrenar mejores modelos de aprendizaje automático.

- **9.** Pulsa el enlace "**<Volver al proyecto**" en la parte superior izquierda.
- 10. Haz clic en el botón "Aprender & Probar".

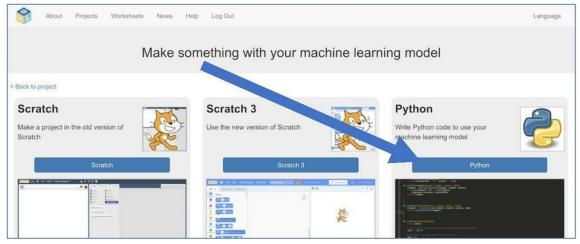
11. Haz clic en el botón "Entrenar un nuevo modelo".



- **12.** Pulsa el enlace "**<Volver al proyecto**" en la parte superior izquierda.
- 13. Haz clic en el botón "Crea".

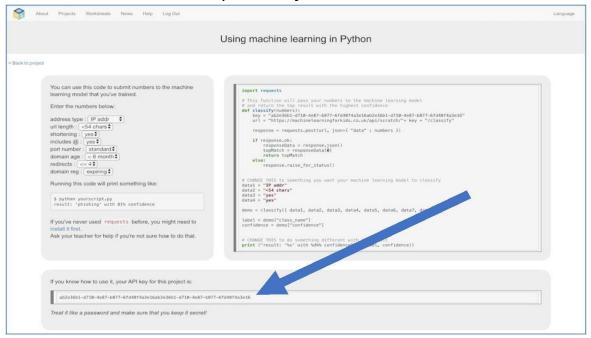


14. Haz clic en el botón "Python".



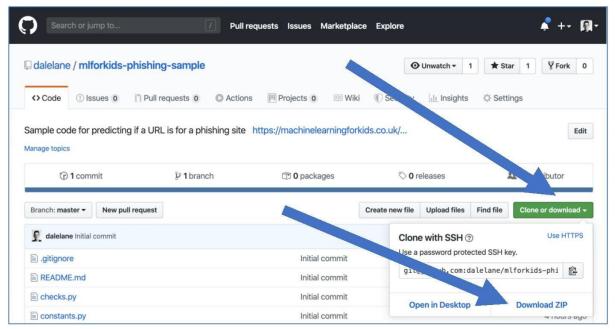
15. Toma nota de tu "clave de API"

Esto es como un código secreto que tu programa Python podrá utilizar para acceder a tu modelo de aprendizaje automático.



Nota: la clave de API en la captura de pantalla anterior es falsa. Las claves API son las contraseñas de like. Yo no compartiría mi clave de API real, y tú no deberías compartir la tuya.

16. Accede a https://github.com/dalelane/mlforkids-phishing-sample y descargar un zip con el proyecto Python de ejemplo



17. Descomprime el archivo zip del proyecto

- **18.** Abre una línea de comandos en la carpeta en la que has descomprimido el código del proyecto.
- **19.** El archivo requirements.txt enumera las bibliotecas de terceros que necesitará para ejecutar el código. La forma más sencilla de instalar todo esto es ejecutar el comando:

```
pip3 install -r requirements.txt
```

Pídele a tu profesor o líder de grupo que te ayude si no estás seguro de cómo hacer esto.

```
Dales-MBP-2:mlforkids-phishing-sample-master dalelane$ pip3 install -r requirements.txt

Collecting certifi=2019.11.28 (from -r requirements.txt (line 1))

Using ocache https://files.pythonstated.org/pockages/96/53/696ca98eadd5b096c550399c3bf1db9do7b5a24de7890bc9cfd5dd9b99/certifi-2019.11.28-py2.py3-none-any.whl

Requirement already satisfied: chardet—3.0.4 in /Library/Frameworks/Python.framework/Versions/3.7/lib/python3.7/site-packages (from -r requirements.txt (line 2)) (0.0.4)

Requirement already satisfied: chardet—3.0.4 in /Library/Frameworks/Python.framework/Versions/3.7/lib/python3.7/site-packages (from -r requirements.txt (line 2)) (0.18.2)

Requirement already satisfied: chardet—3.0.1 (from -r requirements.txt (line 5))

Using cached https://files.python-bacted.org/packages/64/70/640549C3dd48ef87586924207ae8907090de0b306cf2bce5d134d78615cb/python_dateutil=2.8.1-py2.py3-none-any.whl

Requirement already satisfied: python-whois—0.7.2 in /Library/Frameworks/Python.framework/Versions/3.7/lib/python3.7/site-packages (from -r requirements.txt (line 5))

Using cached https://files.python-whois—0.7.2 in /Library/Frameworks/Python.framework/Versions/3.7/lib/python3.7/site-packages (from -r requirements.txt (line 5))

Using cached https://files.python-whois—0.7.2 in /Library/Frameworks/Python.framework/Versions/3.7/lib/python3.7/site-packages (from -r requirements.txt (line 7)) (2.22.0)

Using cached https://files.python-bosted.org/packages/da/40/c9387291310e2fcccd2dcb2c194606c16fe163c695c992b36c11cdf/six-1.13.0-py2.py3-none-ony.whl

Collecting unllib3—1.25.7 (from -r requirements.txt (line 9))

Using cached https://files.pythonhosted.org/packages/da/40/c9387291310e2fcccd2dceb606c16fe163c695c992b36c11cdf/six-1.13.0-py2.py3-none-ony.whl

Installing collecting packages: certifi-2019.6.16

Successfully uninstalled certifi-2019.6.16

Successfully uninstalled certifi-2019.6.16

Successfully uninstalled certifi-2019.6.25

Successfully uninstalled certifi-2019.6.25

Successfully uninstalled certifi-2019.1.28 python-dat
```

20. Abre el archivo "run-test.py" en el editor de código favorito y actualiza MLFORKIDS_API_KEY en línea 4. Introduce la clave de API que ha encontrado en el paso 15.

```
run-test.py

from checks import checkAddressType, checkUrlLength, checkShortening, checkAtSign, checkPortNumber, checkDom
from mlforkids import classify

MLFORKIDS_API_KEY="ab2e36b1-d710-4e87-b077-6fd40f4a3e16ab2e36b1-d710-4e87-b077-6fd40f4a3e16"

def checkUrl(addr):
    address_type = checkAddressType(addr)
    url_length = checkUrlLength(addr)
    includes_at = checkShortening(addr)
    includes_at = checkAtSign(addr)
    port_number = checkPortNumber(addr)
    domain_age = checkDomainAge(addr)
    redirects = checkRedirects(addr)
    domain_reg = checkDomainRegistration(addr)

print (" address type :", address_type)
    print (" url length :", url_length)
    print (" shortening :", shortening)
    print (" includes a :" includes at)
```

21. Ejecutar el programa pithon3 run-test.py

El programa utilizará el modelo de aprendizaje automático que has entrenado para predecir si una variedad de URL es segura o phishing:

https://machinelearningforkids.co. uk/ayuda

Esperemos que se prediga que esto es seguro, ya que yo envío este enlace a la gente muy a menudo!

https://www.bbc.co. uk

Se trata de un sitio web muy antiguo y respetable, registrado en agosto de 1996. Esperemos que piense que es un enlace seguro.

https://en.wikipedia.org/wiki/Machine_learning

La página de Wikipedia de Aprendizaje Automático es otro enlace seguro.

https://91.198.174.192/wiki/Machine_learning

Esta es la misma dirección que arriba - es la dirección de la página de Wikipedia sobre Aprendizaje Automático, pero usando la dirección IP para guardar el navegador web que necesita para buscar la dirección del nombre de dominio de Wikipedia. Es un enlace seguro a visitar, pero es inusual describirlo usando la dirección IP, así que el modelo de aprendizaje automático podría (¿incorrectamente?) pensar que es sospechoso.

https://mickey@bit.ly/35Jnlf8

Esto realmente apunta al sitio web de la BBC News https://www.bbc.co., pero utiliza varias redirecciones para esconder eso, así que el modelo de aprendizaje automático probablemente prediga que es sospechoso.

https://login.bankofamerica.com@www.josueizagirre.com/wp-content/cache/login.bankofamerica.com.uplogad/update.html

Este es un sitio web de phishing que pretendía ser una página del Bank of America. Esperemos que el modelo de aprendizaje automático prediga correctamente que es sospechoso.

http://flinxdeicdccc.com/2612aa892d962d6f8056b195ca6e550d/tnFBsV27sc3kIMJg 0Z8snqenra mMHIXz.php?country=US-United%20States&lang = en

Este es otro sitio web de phishing que esperamos que el modelo de aprendizaje automático reconozca correctamente.

22. Edita el archivo "run-test.py" en un editor de código para probar otras URL.

Consulae cómo se probaron las URL de ejemplos anteriores para aprender a utilizar el checkurl función.

Prueba las direcciones de sitios web legítimos que utilices y confíes para ver si el modelo predice que están a salvo.

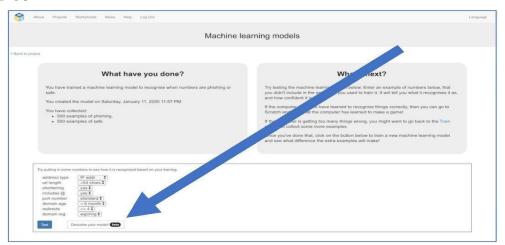
Prueba las direcciones de los sitios web de phishing para ver si el modelo predice que no se puede confiar en ellos. Si necesitas encontrar URLs para phishing,

https://phishtank.com es un buen lugar para mirar. Busca las nuevas URL que sólo se han notificado como sitios de phishing para ver cómo se puede hacer frente a los modelos ML.

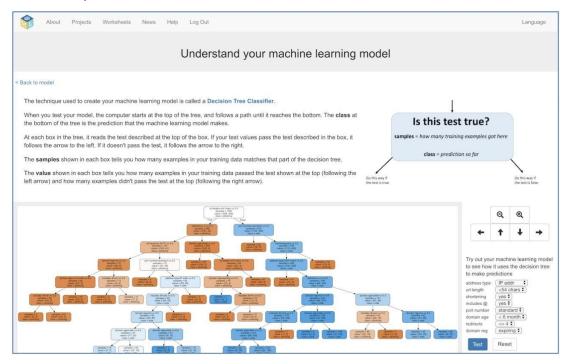
23. Haz clic en el botón "Aprender & Probar" de Machine Learning for Kids.



24. Haz clic en el botón "Describe your model".



25. Examina la visualización para el modelo de aprendizaje automático. Esto muestra cómo el modelo está realizando predicciones. Utiliza el botón **Test** para ver cómo funciona.



¿Qué has hecho?

Has utilizado un conjunto de datos prepreparados para entrenar un tipo de modelo de aprendizaje automático llamado "clasificador de árbol de decisión" para que pueda predecir si una URL va a ser un sitio web legítimo o un sitio web de phishing.

Has utilizado el modelo de aprendizaje automático de un programa de Python, que has modificado para que pueda hacer predicciones sobre tus propias direcciones web.

26. ¡ Planifica tu propio proyecto!

La importación de la plantilla significa que no tienes que decidir qué características debe utilizar el modelo de aprendizaje automático.

El proyecto ha utilizado ocho características (descritas en el paso 8 anterior).

Piensa en cómo podría mejorar el modelo de aprendizaje automático añadiendo características adicionales. ¿Qué otros atributos acerca de los sitios web crees que ayudarán al modelo de aprendizaje automático a ser mejor al reconocer las URL de phishing? Las siguientes páginas incluyen enlaces a algunos proyectos de investigación sobre este tema que podrían ayudar a darles algunas ideas.

Investigación de aprendizaje automáticosobre Phishing

Los modelos de aprendizaje automático para reconocer las URL de phishing es un tema activo en la investigación ML.

Intenta ver algunos de los documentos que se listan a continuación.

Incluso si no entiendes todo lo que dicen, la ejecución de tu propio experimento debería ayudarte a conseguir la idea general.

¿Alguna de estos papeles te da una idea para tu propio proyecto?

https://ibm.biz/phishing-hassan

En este artículo se describe la investigación de Hassan sobre 30 atributos diferentes de los enlaces de phishing. Doce de estos se basan en atributos de la URL, como hiciste en el proyecto. Algunos atributos que se describen se basan en la forma en que se visualizó el enlace. Por ejemplo, si el enlace de phishing estaba en un correo electrónico, ¿se visualizaba el URL cuando se pasa el puntero del ratón por encima del enlace?

https://ibm.biz/phishing-rajab

En este artículo se describe la investigación de Rajab sobre cómo decir qué características son las más útiles para reconocer las URL de phishing. Identificaron el protocolo (si la página se inicia con http o https) y si el certificado SSL para un sitio web está firmado por un origen de confianza como dos de los atributos más significativos que se deben utilizar.

https://ibm.biz/phishing-joshi

Joshi & Pattanshetti describe 48 atributos que encontraron para ser útiles, incluyendo si la página contiene formularios seguros, si los formularios en la página tratan de enviar correos electrónicos, si el icono de la barra de direcciones parece válido, y muchos más.

http://ibm.biz/phishing-basnet

Basnet, Sung & Lui describen cómo revisaron 177 atributos diferentes de URL's para identificar el más útil para entrenar un modelo de aprendizaje automático.

Algunos de ellos revisaron el contenido de las páginas web, no sólo la dirección URL, como contar el número de enlaces en la página, si la página contiene iframes, si tiene campos de contraseña en ella, etc.

https://ibm.biz/phishing-mohammad

Mohammad, Thabtah y McCluskey describen una variedad de características que se identifican como útiles, algunas basadas en URL como lo han hecho, pero algunas basadas en el uso de JavaScript en páginas web, y algunos usando datos de fuentes externas como Google, PhishTank, Alexa, y otros.

Describen los atributos que han utilizado muy claramente, y debes reconocer varias de estas características de las características del proyecto.

https://ibm.biz/phishing-shirazi

Shirazi, Haefner & Ray se basan en el artículo Mohammad et al descrito más arriba, y dicen cómo identificaron los 10 atributos más útiles que usaban para hacer "Fresh-Phish".

Uno de ellos fue el ranking de Google para una URL, confiando en Google para tener un rango alto para sitios web legítimos.

https://ibm.biz/phishing-whittaker

Whittaker, Ryner & Nazif describen cómo Google ha evaluado las URL para identificar las páginas de phishing.

Describen características como la presencia de términos como "customerservice" en la URL, que se descubrió que eran más comunes en los sitios de phishing.